

Análise de dados de Metagenômica

Dalmolin Systems Biology Group

Índice

Processamento e Análise de Dados de Metagenoma	3
1 Organizando Ambiente para Análise	4
2 Controle de Qualidade e Pré-processamento	5
2.1 Baixar Amostras	5
2.2 Controle de Qualidade com FastQC e MultiQC	5
2.2.1 Estrutura de Arquivos .fastq	5
2.2.2 Ferramentas de Controle de Qualidade	6
2.2.3 Gerando Relatórios de Qualidade	6
2.3 Pré-processamento das leituras	7
2.3.1 Contexto	7
2.3.2 Removendo sequências de baixa qualidade	7
2.3.3 Remoção de Sequências do Hospedeiro	8
3 Montagem	10
3.1 Contexto	10
3.2 Realizando a montagem	10
4 Classificação Taxonômica	12
4.1 Contexto	12
4.2 Adquirindo o banco de dados	12
4.3 Realizando a classificação taxonômica	13
5 Anotação Funcional	15
5.1 Contexto	15
5.2 annotate	15
5.2.1 Alinhamento	15
5.2.2 Executando o annotate	16
5.3 eggNOG-mapper	18

Processamento e Análise de Dados de Metagenoma

Aviso

O curso ainda está em construção então certos comandos podem não funcionar como esperado!

Neste repositório está o material para o curso **Análise de dados de Metagenômica**, organizado pelo Prof. Rodrigo Dalmolin, do Centro Multiusuário de Bioinformática da UFRN.

O curso é dividido em 4 módulos:

- Controle de qualidade e pré-processamento
- Montagem
- Classificação taxonômica
- Anotação funcional

1 Organizando Ambiente para Análise

Primeiro, é necessário criar e ativar um ambiente Conda que contenha todas as ferramentas necessárias para os próximos passos. Caso ainda não tenha o Conda instalado, siga as instruções [neste link](#).

Vá até [este link](#) para adquirir o arquivo `environment.yml`.

```
conda env create -f environment.yml
conda activate metagenomicsTraining
```

A estrutura de diretórios a seguir ajudará na organização dos arquivos baixados, arquivos intermediários e seus outputs:

```
mkdir -p ./Pipeline/{result,data/{merged,assembled,collapsed,removal/{index,reference},raw,t
```

2 Controle de Qualidade e Pré-processamento

2.1 Baixar Amostras

Mude para o diretório `Pipeline/data` e baixe os dados de exemplo:

```
cd Pipeline/data  
  
prefetch SRR579292 -X 20G
```

Nota

No comando `prefetch`, o argumento `-X` especifica o tamanho máximo do arquivo a ser baixado (adapte esse argumento se necessário).

Obtenha as leituras paired-end:

```
fasterq-dump SRR579292 -e 8
```

Nota

O argumento `-e` no comando `fasterq-dump` especifica o número de threads que serão utilizadas. Adapte este argumento conforme o desempenho do seu sistema.

2.2 Controle de Qualidade com FastQC e MultiQC

2.2.1 Estrutura de Arquivos `.fastq`

O formato `.fastq` contém as sequências de DNA geradas no sequenciamento, junto com informações sobre a qualidade de cada nucleotídeo. A estrutura de um arquivo `.fastq` segue um padrão repetitivo a cada fragmento sequenciado:

1. **Linha 1:** Contém o identificador único da leitura, que pode incluir informações sobre o sequenciador e a amostra (começa com o símbolo `@`).

2. **Linha 2:** A sequência de nucleotídeos resultante do sequenciamento.
3. **Linha 3:** Opcionalmente usada para anotações ou descrições adicionais (começa com um símbolo +).
4. **Linha 4:** A qualidade de cada base na sequência, representada pelo Phred Score, que reflete a confiabilidade da leitura.

A imagem abaixo exemplifica essa estrutura:

```
@Sample Label
AATGATACGGCGTATGTATTCCTCCTATTTGCGAAGTCCAATGGTGCGTATATGCCTTCTGCTTGTC
+
{:F:FFFFFFF,FFHHHF4FFFFF<FED@FFFF:F,,FFFF9C;=?FFF?2AADDFF:FF:FF?GBB?<F99FPFF
```

- **Em Roxo:** Identificador do sequenciamento.
- **Em Laranja:** Sequências adaptadoras (caso ainda não tenham sido removidas), que podem variar dependendo da plataforma de sequenciamento.
- **Em Azul:** O fragmento de DNA sequenciado, conhecido como “*Insert Size*”.
- **Em Verde:** Phred Score, que indica a qualidade de cada base na sequência.

2.2.2 Ferramentas de Controle de Qualidade

Para garantir que as sequências obtidas sejam de boa qualidade e adequadas para análise, utilizamos ferramentas como o **FastQC** e o **MultiQC**.

- **FastQC:** Avalia a qualidade de cada arquivo de sequenciamento individualmente, gerando relatórios com informações sobre a qualidade das bases, conteúdo GC, presença de adaptadores e outros aspectos que podem impactar a análise.
- **MultiQC:** Agrega os relatórios gerados pelo FastQC (ou outras ferramentas), criando um único relatório consolidado que facilita a visualização e interpretação dos dados de múltiplas amostras.

2.2.3 Gerando Relatórios de Qualidade

Para gerar relatórios de controle de qualidade com o FastQC para cada uma das amostras baixadas, use o seguinte comando:

```
# Gerando relatórios de qualidade para cada amostra
for sample in $(ls Pipeline/data/*.fastq.gz);
do
fastqc $sample -o Pipeline/data
done
```

Gere o relatório consolidado contendo todas as amostras a partir do output do FastQC:

```
# Consolidando relatórios com MultiQC
multiqc Pipeline/data
```

Interpretando os resultados do MultiQC

Verifique os gráficos de qualidade, presença de contaminantes e distribuições de qualidade das bases. Ajustes podem ser necessários para garantir a integridade dos dados para as etapas seguintes.

2.3 Pré-processamento das leituras

2.3.1 Contexto

Como vimos na seção anterior, nosso arquivo pode ter sequências de baixa qualidade, sejam estas sequências adaptadoras ou simplesmente erros no procedimento do sequenciamento. Portanto, devemos remover essas sequências de nossas análises posteriores, a fim de não permitir que interfiram com ruído na informação biológica real.

Para isso, obteremos uma amostra de sequenciamento (que será utilizada em todas as seções posteriores) e a processaremos com ferramentas de controle de qualidade, além de alinhar a amostra, de origem na microbiota humana, contra o genoma referência do hospedeiro, garantido que tenhamos apenas sequências advindas da microbiota.

2.3.2 Removendo sequências de baixa qualidade

Remova sequências de baixa qualidade e adaptadores:

```
fastp -i SRR579292_1.fastq -I SRR579292_2.fastq -o trimmed/SRR579292_1_trim.fastq -O trimmed/
```

Nota

No comando **fastp**, o argumento **-q** define o limiar da pontuação de qualidade Phred, e **-w** especifica o número de threads a serem usadas (adapte esses argumentos se necessário).

Um genoma de referência de *Homo sapiens* é necessário para remover as sequências do hospedeiro desses dados. Mude o diretório atual para "Pipeline/data/removal/reference" e baixe um genoma de referência do Ensembl.

2.3.3 Remoção de Sequências do Hospedeiro

Baixe o genoma de referência de *Homo sapiens* do Ensembl:

```
wget ftp://ftp.ensembl.org/pub/release-102/fasta/homo_sapiens/dna/Homo_sapiens.GRCh38.dna.pr  
pigz -d Homo_sapiens.GRCh38.dna.primary_assembly.fa.gz -p 8
```

i Nota

O software `pigz` é uma implementação paralela do `gzip`. O argumento `-p` especifica o número de threads a serem usadas.

Construa um índice Bowtie2:

```
bowtie2-build Homo_sapiens.GRCh38.dna.primary_assembly.fa ../index/host --threads 8
```

Volte para "Pipeline/data" e alinhe as sequências contra a referência:

```
bowtie2 -x removal/index/host -1 trimmed/SRR579292_1_trim.fastq -2 trimmed/SRR579292_2_trim.
```

Extraia as leituras não alinhadas:

```
samtools view -bS removal/all.sam > removal/all.bam  
samtools view -b -f 12 -F 256 removal/all.bam > removal/unaligned.bam  
samtools sort -n removal/unaligned.bam -o removal/unaligned_sorted.bam  
samtools bam2fq removal/unaligned_sorted.bam > removal/unaligned.fastq  
cat removal/unaligned.fastq | grep '^@./1$' -A 3 --no-group-separator > removal/unaligned_1  
cat removal/unaligned.fastq | grep '^@./2$' -A 3 --no-group-separator > removal/unaligned_2
```

i Nota

No comando `SAMtools`, os argumentos `-f` e `-F` utilizam flags para especificar, respectivamente, quais alinhamentos devem ser extraídos e quais não devem ser extraídos. Consulte [esta documentação](#) para saber mais sobre as flags disponíveis no `SAMtools`.

Una as leituras paired-end:

```
fastp -i removal/unaligned_1.fastq -I removal/unaligned_2.fastq -o trimmed/unmerged_1.fastq
```

Remova sequências duplicadas:


```
fastx_collapser -i merged/SRR579292_merged.fastq -o collapsed/SRR579292.fasta
```

3 Montagem

3.1 Contexto

As *reads*, ou leituras, fragmentos de sequências gerados pelo processo de sequenciamento, podem ser re-organizadas e mescladas em sequências mais longas e contíguas, ou *contigs*. Esse processo é denominado de **Montagem**.

Para se realizar montagem, você pode utilizar uma referência, como o genoma referência de um organismo, que servirá como base para organizar as *contigs*. No entanto, no contexto metagenômico, a modalidade de montagem geralmente realizada é a montagem livre de referência, ou montagem *de novo*.

Como montador *de novo*, utilizaremos o [MEGAHIT](#).



Figura 3.1: [Bioinformaticamente](#)

3.2 Realizando a montagem

Vamos montar as leituras pós-descontaminação usando o MEGAHIT:

```
megahit -1 ../removal/unaligned_1.fastq -2  
../removal/unaligned_2.fastq -o SRR579292 -t 8
```

O arquivo de saída `SRR579292.contigs.fa` contém as sequências contíguas correspondentes às leituras usadas.

i Nota

Os passos seguintes, como a classificação taxonômica, podem se utilizar tanto das leituras quanto dos contigs. Iremos utilizar as leituras por motivos de didática, mas a maioria das ferramentas utilizadas para a análise de metagenômica podem fazer uso tanto de *reads* quanto de *contigs*.

4 Classificação Taxonômica

4.1 Contexto

O passo de classificação taxonômica trata de classificar as sequências mistas, sejam leituras ou contíguas, de uma amostra metagenômica em táxons claramente definidos, e tipicamente acompanha um perfil de abundância desses táxons.

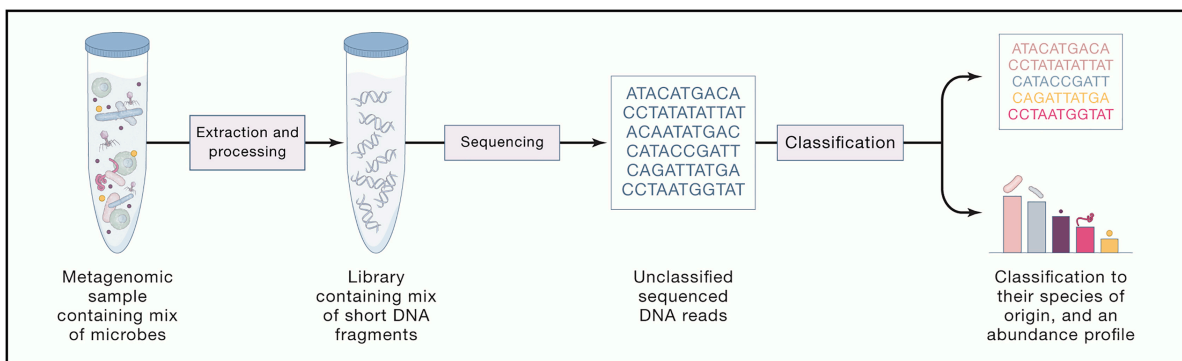


Figura 4.1: [Ye et al, 2019](#)

4.2 Adquirindo o banco de dados

Mude o diretório atual para "Pipeline/alignment/db" (pois esse banco também será usado na seção Seção 5.2.1, do alinhamento) e baixe o banco de dados de proteínas do NCBI-nr:

⚠ Aviso

O banco de dados é **muito grande e inviável** de se instalar em um computador pessoal. Use um cluster de alta performance ou ambientes similares!

```
wget ftp://ftp.ncbi.nlm.nih.gov/blast/db/FASTA/nr.gz
pigz -d nr.gz -p 8
```

Construa um índice DIAMOND:

```
diamond makedb --in nr -d ../index/nr
```

Mude o diretório atual para “Pipeline/taxonomic/db” e baixe os seguintes arquivos:

```
wget ftp://ftp.ncbi.nlm.nih.gov/pub/taxonomy/taxdump.tar.gz
wget ftp://ftp.ncbi.nlm.nih.gov/pub/taxonomy/accession2taxid/prot.accession2taxid.gz
```

Esses são os bancos de dados que utilizaremos para executar o Kaiju

Extraia e descompacte os arquivos necessários:

```
tar -xf taxdump.tar.gz nodes.dmp names.dmp
pigz -d prot.accession2taxid.gz -p 8
```

Construa um índice Kaiju:

```
kaiju-convertNR -t nodes.dmp -g prot.accession2taxid -e ~/miniconda3/envs/medusaPipeline/bin/
kaiju-mkbt -n 8 -a ACDEFGHIKLMNPQRSTVWY -o kaijuNR kaijuNR.fasta
kaiju-mkfmi kaijuNR
```

i Nota

Na chamada `kaiju-convertNR`, por padrão, são incluídas apenas sequências de Archaea, Bactérias e Vírus do NCBI-nr. Este comportamento pode ser alterado com o argumento `-l`, passando um arquivo de entrada como `~/miniconda3/envs/medusaPipeline/bin/kaiju-taxonlistEuk.tsv`. Este argumento utiliza apenas sequências com ancestrais listados no arquivo.

4.3 Realizando a classificação taxonômica

Mude o diretório atual para “Pipeline/taxonomic” e execute a classificação taxonômica:

```
kaiju -t db/nodes.dmp -f db/kaijuNR.fmi -i ../data/removal/unaligned_1.fastq -j ../data/remov
```

Adicione os nomes dos táxons ao output:

```
kaiju-addTaxonNames -t db/nodes.dmp -n db/names.dmp -r superkingdom,phylum,class,order,famil
```

Gere os gráficos Krona:

```
kaiju2krona -t db/nodes.dmp -n db/names.dmp -i ../result/SRR579292_kaiju.out -o ../result/SRR579292_krona.out  
ktImportText -o ../result/SRR579292_krona.html ../result/SRR579292_kaiju2krona.out
```

5 Anotação Funcional

5.1 Contexto

Muitas vezes, uma análise metagenômica não está completa após a classificação taxonômica - afinal, um estudo composicional, apesar de útil, não mostra exatamente o que pode estar acontecendo em um microambiente em termos de vias metabólicas e funções biológicas. Para esse fim, portanto, temos o passo de anotação funcional, que consiste de inferir funções a partir das sequências obtidas do microbioma, se utilizando ou não da informação taxonômica.

5.2 annotate

Para nosso primeiro exemplo, vamos utilizar a ferramenta [annotate](#), que irá transferir identificadores de um resultado de alinhamento para identificadores funcionais, nesse caso termos do [Gene Ontology](#).

Mas, para fazer isso, primeiro precisamos alinhar nosso dado a uma referência!

5.2.1 Alinhamento

5.2.1.1 Realizando o alinhamento

Mude o diretório atual para "Pipeline/alignment" e alinhe as leituras contra o banco de dados de proteínas de referência (obtido na seção [Seção 4.2](#)):

```
touch unaligned.fasta
diamond blastx -d index/nr -q ../data/collapsed/SRR579292.fasta -o matches.m8 --top 3 --un un
```

i Nota

No comando DIAMOND, o argumento `--un` especifica o arquivo usado para gravar as sequências não alinhadas, e `--top 3` reporta alinhamentos dentro dessa porcentagem da melhor pontuação de alinhamento.

O DIAMOND pode usar muita memória e espaço temporário em disco. Portanto, o programa pode falhar ao esgotar um desses recursos. O argumento `-b` especifica o tamanho do bloco e `-c` o número de partes para processamento do índice. O uso total de memória pode ser estimado aproximadamente como $2(b+9b/c)$ GB. Em um servidor com alta memória, defina `-c 1`.

Realize um alinhamento mais sensível usando as sequências não alinhadas:

```
touch unaligned2.fasta
diamond blastx -d index/nr -q unaligned.fasta -o matches2.m8 --more-sensitive --top 3 --un u
```

i Nota

O modo padrão sensível é projetado para leituras curtas (~100 pb), encontrando hits com >60% de identidade. Para sequências mais longas, os modos sensíveis são recomendados. O DIAMOND é muito mais eficiente para arquivos grandes (>1 milhão de leituras).

Verifique o número de consultas que apresentam hits com pelo menos 80% de identidade em `matches2.m8`:

```
awk '{ if ($3>=80) { print } }' matches2.m8 > check.m8
```

```
awk '{a[$1]++}END{for (i in a) sum+=1; print sum}' check.m8
```

5.2.1.2 Concatenar os resultados do alinhamento:

```
cat matches.m8 matches2.m8 > all_matches.m8
```

5.2.2 Executando o annotate

- Vamos primeiro filtrar as colunas do nosso arquivo de referência para as que contém identificadores do GenBank e do Gene Ontology:

```
awk -F "\\t" '{if((\\$7!="") && (\\$18!="")){print \\$18"\\t"\\$7}}' idmapping_selected.tab > gen
```

- E fazer o mesmo para termos um arquivo que traduz identificadores RefSeq para Gene Ontology:


```
awk -F "\\t" '{if((\\$4!="") && (\\$7!="")){print \\$4"\\t"\\$7}}' idmapping_selected.tab > refs
```

- Podemos então executar [um script R](#) que irá limpar os dois arquivos, preparando-os para o formato do annotate:

Aviso

O script requer bastante memória para lidar com o arquivo de mapeamento do UniProt, podendo requerir até 80GB de memória RAM para um dicionário típico.

```
createDictionary.R \  
  NR2G0.txt \  
  genbank2G0.txt \  
  refseq2G0.txt \  
  4
```

- Em sequência, criamos o banco de dados do annotate:

```
annotate createdb NR2G0.txt NR2G0 0 1 -d db
```

- E executamos o annotate para anotar cada *query* do alinhamento para seu identificador funcional:

```
annotate idmapping ../alignment/all_matches.m8 ../result/SRR579292_functional_G0.txt NR2G0 -l
```

Nota

O argumento `-l` determina qual o comprimento mínimo de um alinhamento para ele ser considerado.

- Ao explorar o arquivo de resultado do annotate podemos ver que ele possui o seguinte formato:

Query	Annotation
342-2	G0:0005829; G0:0008720; G0:0047964; G0:0030267; G0:0016618; G0:0051287
1560-1	G0:0005829; G0:0005886; G0:0003854; G0:0102294; G0:0070403; G0:0016616; G0:0004769; G0:0005829
3588-1	G0:0000775; G0:0005737; G0:0005829; G0:0090443; G0:0110085; G0:0044732; G0:0005634; G0:0005829
5204-1	G0:0016491; G0:0008202
7527-1	Unknown
9319-1	G0:0042802; G0:0030170; G0:0008483; G0:0006520; G0:0009058
9922-1	G0:0000775; G0:0005737; G0:0005829; G0:0090443; G0:0110085; G0:0044732; G0:0005634; G0:0005829
10306-1	Unknown
12743-1	G0:0005524; G0:0140658; G0:0004386; G0:0016787

Para cada busca (“Query”) do seu alinhamento original, temos uma ou mais anotações em termos do Gene Ontology (“Annotation”)

5.3 eggNOG-mapper

O eggNOG-mapper é uma ferramenta que realiza anotação funcional de sequências contíguas. Ele usa informação de ortologia e filogenia para transferir identificadores funcionais às sequências. O eggNOG-mapper pode ser executado através de uma [interface web](#) mas aqui ilustraremos seu uso na linha de comando.

Para isso, vamos utilizar as sequências contíguas que montamos anteriormente, na Seção 3.

- O eggNOG-mapper pode ser executado da seguinte maneira:

```
emapper.py \
  -m diamond \
  --itype metagenome \
  -i SRR579292.contigs.fa \
  -o eggnog_results/SRR579292 \
  --cpu 6
```

As opções que utilizamos foram:

- **-m**: Sinaliza o “modo” de execução do eggnog, neste caso a ferramenta que será utilizada para realizar a busca por sequências. No nosso caso utilizamos o DIAMOND, ferramenta que já conhecemos na Sessão 5.2.1.
- **--itype**: Sinaliza o tipo de entrada (*input*) que damos a ferramenta, no nosso caso sequência contíguas originadas de um metagenoma.
- **-i**: Determina a entrada para a ferramenta.
- **-o**: Determina para onde deve ser escrita a saída da ferramenta.
- **--cpu**: O número de núcleos de processamento a serem utilizados pela ferramenta.

Uma vez que executamos o eggNOG-mapper, teremos um resultado no seguinte formato (eggnog_results/SRR579292.emapper.annotations):

#query	seed_ortholog	evaluate	score	eggNOG_OGs	max_annot_lvl	COG_category	Descr
k141_94572	552396.HMPREF0863_01053	4.43e-45	159.0	COG0595@1 root,COG0595@2 Bac			
k141_47286	1236514.BAKL01000034_gene2896	3.35e-79	254.0	COG5009@1 root,COG500			
k141_141858	158189.SpiBuddy_1606	8.08e-76	239.0	COG1593@1 root,COG1593@2 Bac			
k141_23643	272563.CD630_25090	3.3e-45	159.0	COG1486@1 root,COG1486@2 Bacteria,1T			
k141_70929	1122985.HMPREF1991_02897	3.54e-11	65.5	COG1595@1 root,COG15			

Bastante informação! Mas essencialmente semelhante à ferramenta anterior: Temos em cada linha uma sequência de busca advinda do nosso arquivo de montagem, e em cada uma das outras colunas, anotações para diferentes bancos de dados de informação funcional, além de colunas detalhando a qualidade de alinhamento das nossas sequências à esses identificadores.

Para mais informações sobre o arquivo de saída do eggNOG-mapper, confira a [documentação da ferramenta](#).