

Análise de dados de Metagenômica

Dalmolin Systems Biology Group

Table of contents

Processamento e Análise de Dados de Metagenoma	3
1 Organizando Ambiente para Análise	4
2 Controle de Qualidade e Pré-processamento	5
2.1 Baixar Amostras	5
2.2 Controle de Qualidade com FastQC e MultiQC	5
3 Montagem	6
4 Classificação Taxonômica	7
5 Anotação Funcional	8
6 Análises Downstream	9
6.1 Cálculos de Diversidade	9
6.2 Extraindo informação funcional	9

Processamento e Análise de Dados de Metagenoma

Neste repositório está o material para o curso **Análise de dados de Metagenômica**, organizado pelo Prof. Rodrigo Dalmolin, do Centro Multiusuário de Bioinformática da UFRN.

O curso é dividido em 5 módulos:

- Controle de qualidade e pré-processamento
- Montagem
- Classificação taxonômica
- Anotação funcional
- Análises downstream:
 - Cálculos de diversidade e visualizações
 - Visualizações da anotação funcional

1 Organizando Ambiente para Análise

Primeiro, é necessário criar e ativar um ambiente Conda que contenha todas as ferramentas necessárias para os próximos passos. Caso ainda não tenha o Conda instalado, siga as instruções [neste link](#).

```
$ conda env create -f medusaPipeline.yml
$ conda activate medusaPipeline
```

A estrutura de diretórios a seguir ajudará na organização dos arquivos baixados, arquivos intermediários e seus outputs:

```
$ mkdir -p ./Pipeline/{result,data/{merged,assembled,collapsed,removal/{index,reference},raw
```

2 Controle de Qualidade e Pré-processamento

2.1 Baixar Amostras

Mude para o diretório `Pipeline/data` e baixe os arquivos de exemplo em pares (pair-end):

```
$ cd Pipeline/data
$ fasterq-dump SRR579292 -e 8
```

Nota: O argumento `-e` no comando `fasterq-dump` especifica o número de threads que serão utilizadas. Adapte este argumento conforme o desempenho do seu sistema.

2.2 Controle de Qualidade com FastQC e MultiQC

Sobre arquivos .fastq: O formato `.fastq` contém sequências de leitura e suas qualidades, sendo essencial para análises de sequenciamento.

FastQC: Ferramenta que gera relatórios de controle de qualidade para arquivos de sequenciamento, destacando problemas como baixa qualidade de base.

MultiQC: Consolida os relatórios do FastQC em um único documento, facilitando a visualização geral da qualidade das amostras.

Gere o relatório de controle de qualidade para cada amostra baixada com o FastQC:

```
# Gerando relatórios de qualidade para cada amostra
for sample in $(ls Pipeline/data/*.fastq.gz) do fastqc $sample -o Pipeline/data done
```

Gere o relatório consolidado contendo todas as amostras a partir do output do FastQC:

```
# Consolidando relatórios com MultiQC
$ multiqc Pipeline/data
```

Interpretando os resultados do MultiQC: Verifique os gráficos de qualidade, presença de contaminantes e distribuições de qualidade das bases. Ajustes podem ser necessários para garantir a integridade dos dados para as etapas seguintes.

3 Montagem

 WORK IN PROGRESS

4 Classificação Taxonômica


 WORK IN PROGRESS

5 Anotação Funcional



WORK IN PROGRESS

6 Análises Downstream

 WORK IN PROGRESS

6.1 Cálculos de Diversidade

6.2 Extraíndo informação funcional